Nama: Pandya Zannito Prawoko
NIM: 2802533163

BAGIAN A: Analisis Konseptual

1. Efek Regularisasi pada Batch Normalization

- Mekanisme Statistik Mini-Batch: Batch Normalization menormalisasi aktivasi berdasarkan rata - rata dan varians mini - batch, bukan keseluruhan dataset. Fluktuasi statistik antar mini - batch ini memasukkan sedikit derau (noise) ke dalam aktivasi, yang bertindak sebagai regularisasi ringan dan juga mengurangi ketergantungan pada inisialisasi. Hal ini biasanya sering kali dapat menghilangkan kebutuhan akan Dropout.
- Skenario Pengecualian: Asumsi ini tidak berlaku pada ukuran mini - batch yang sangat kecil, di mana estimasi statistik menjadi tidak stabil, atau pada tugas dengan risiko overfitting ekstrem yang memerlukan regularisasi struktural independen seperti Dropout untuk mencegah co-adaptation neuron.

  Slide 6–8.

2. Degradasi Jaringan Dalam dan Formulasi Residual

- Masalah Degradasi: Penambahan kedalaman lapisan pada plain CNN menurunkan akurasi pelatihan akibat vanishing/exploding gradient serta hilangnya informasi lintas lapisan, membuat model sulit dioptimalkan meskipun secara teoritis mampu meniru model dangkal melalui identity mapping.
- Formulasi Aliran Gradien: Skip connection mengubah formulasi output menjadi Y = F(x) + x Saat backpropagation, jalur identitas (x) memungkinkan gradien mengalir langsung tanpa tereduksi perkalian matriks berulang.
- Mitigasi Vanishing Gradient: Mekanisme ini memitigasi vanishing gradient (yang dibahas pada Sesi 02) dengan menjamin komponen gradien minimal bernilai 1 tetap sampai ke lapisan awal, menjaga stabilitas pelatihan jaringan sangat dalam.

  Slide 10–12.

3. Feature Extraction vs. Fine-Tuning

- Dimensi Perbandingan:

    1. Parameter Terbarui: Feature Extraction memperbarui sedikit parameter (hanya classifier head), sedangkan Fine-Tuning memperbarui sebagian/seluruh lapisan.

2. Volume Data: Feature Extraction cocok untuk data sangat sedikit; Fine-Tuning membutuhkan data lebih besar.
3. Beban Komputasi: Feature Extraction lebih ringan karena aktivasi backbone dapat dicache; Fine-Tuning memori-intensif.
4. Risiko Destructive Updates: Feature Extraction bebas risiko merusak representasi bawaan, sementara Fine-Tuning berisiko tinggi jika learning rate terlalu besar.

- Kriteria Praktis: Pilih Feature Extraction jika data target sangat terbatas dan mirip dengan dataset sumber; pilih Fine-Tuning jika dataset target cukup besar atau domainnya berbeda signifikan.

  Slide 14–16.

4. Kaidah Penerapan Data Augmentation

- Pertimbangan Metodologis: Data augmentation hanya diaktifkan pada train set untuk mensimulasikan data tambahan dan meningkatkan kemampuan generalisasi model. Teknik ini harus dinonaktifkan pada validation/test set agar evaluasi performa mencerminkan data dunia nyata yang objektif, konsisten, dan tidak terdistorsi.
- Contoh Tidak Layak: Pembalikan vertikal (vertical flip) tidak layak untuk klasifikasi ras hewan peliharaan (pet breeds). Hewan peliharaan secara natural tidak pernah muncul dalam orientasi terbalik di dunia nyata, sehingga transformasi ini melanggar invariansi semantik label dan merusak makna alami objek citra.

  Slide 20, 21, 23.

5. Mitigasi Catastrophic Forgetting

- Mekanisme Hilangnya Representasi: Catastrophic forgetting terjadi ketika adaptasi model berlangsung terlalu agresif sehingga menimpa bobot representasi universal (fitur generik dasar) yang dipelajari dari dataset besar, menyebabkan model melupakan pengetahuan awalnya.
- Strategi Mitigasi:
  1. Differential learning rate: Menggunakan learning rate sangat kecil pada lapisan awal dan lebih besar pada lapisan akhir, menjaga stabilitas fitur dasar.
  2. Gradual unfreezing: Membuka lapisan secara bertahap dari atas ke bawah untuk adaptasi yang terkontrol. Alasan teoritisnya adalah mempertahankan ekstraktor fitur umum sambil memberi fleksibilitas penyesuaian pada lapisan spesifik tugas baru.

  Slide 28–29.

BAGIAN C: Laporan dan Analisis

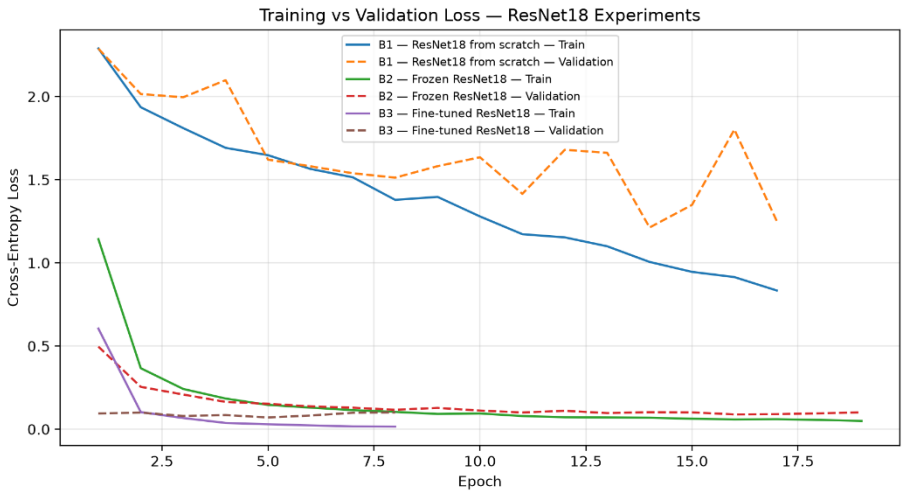
C1. Tabel Konsolidasi dan Visualisasi Pembelajaran

Bagian ini menyajikan perbandingan hasil lima eksperimen CNN, yaitu B1 hingga B5, yang dirancang untuk mengevaluasi pengaruh strategi pelatihan, penggunaan pretrained weights, fine-tuning, augmentasi data, dan pemilihan arsitektur terhadap kinerja klasifikasi citra. Perbandingan dilakukan berdasarkan jumlah trainable parameters, learning rate, epoch terbaik berdasarkan validation loss, durasi pelatihan, validation accuracy, dan test Macro F1-score. Selain itu, kurva training loss dan validation loss pada B1, B2, dan B3 digunakan untuk mengamati dinamika pembelajaran serta kemampuan generalisasi masing-masing konfigurasi.

Eksperimen	Strategi	Trainable parameters	Learning rate	Epoch terbaik / total	Akurasi validasi	Akurasi validasi	Waktu training
B1	ResNet18 dari nol	11.181.642	0,001	14 / 17	57,91%	0,5719	7.03 m
B2	ResNet18 pretrained, backbone dibekukan	5.130	FC: 0,001	16 / 19	96,97%	0,9731	6.54 m
B3	ResNet18 pretrained, layer4 dan FC di-fine-tune	8.398.858	Layer4: 0,0001; FC: 0,001	5 / 8	97,64%	0,9765	2.74 m
B4-a	ResNet18 pretrained, dengan augmentation	5.130	FC: 0,001	16 / 19	96,97%	-	6.62 m
B4-b	ResNet18 pretrained, tanpa augmentation	5.130	FC: 0,001	20 / 23	96,97%	0,9765	6.56 m
B5	MobileNetV2 pretrained, backbone dibekukan	12.810	Classifier: 0,001	30 / 30	96,63%	0,9662	12.42 m

*Catatan: FC = fully connected classifier. Seluruh eksperimen menggunakan AdamW dengan weight decay 0,01. *History B4-A identik dengan B2 sehingga hasilnya belum dapat dianggap sebagai eksperimen augmentation yang independen. Durasi training tidak tersimpan dalam log yang tersedia.*

Berdasarkan Tabel tersebut, eksperimen B3 menghasilkan validation accuracy dan test Macro F1-score tertinggi di antara konfigurasi yang hasilnya dapat diverifikasi, masing-masing sebesar 97,64% dan 0,9765. Sementara itu, B2 mencapai test Macro F1-score sebesar 0,9731 dengan hanya 5.130 trainable parameters. B5 juga menunjukkan performa yang kompetitif dengan 12.810 trainable parameters dan test Macro F1-score sebesar 0,9662. Sebaliknya, B1 yang dilatih dari awal memperoleh test Macro F1-score sebesar 0,5719. Perbedaan ini menunjukkan bahwa penggunaan pretrained weights berkaitan dengan peningkatan performa yang besar pada dataset yang digunakan. Namun, hasil B4-A belum dapat digunakan untuk menarik kesimpulan yang valid mengenai pengaruh augmentasi karena riwayat pelatihan dan checkpoint-nya identik dengan B2.



C2. Pembahasan Analisis Komparatif

1. Perbandingan Training from Scratch dan Transfer Learning

Eksperimen B1 memperoleh test Macro F1 sebesar 0,5719, jauh di bawah B2 sebesar 0,9731 dan B3 sebesar 0,9765. Hal ini menunjukkan keunggulan transfer learning pada dataset terbatas. Model pretrained telah mempelajari fitur visual umum dari ImageNet, sehingga tidak perlu mempelajari seluruh representasi dari awal. Sebaliknya, B1 harus mempelajari fitur sekaligus melakukan klasifikasi menggunakan data yang tersedia, sehingga lebih sulit mencapai generalisasi yang baik.

2. Trade-off Feature Extraction dan Fine-tuning

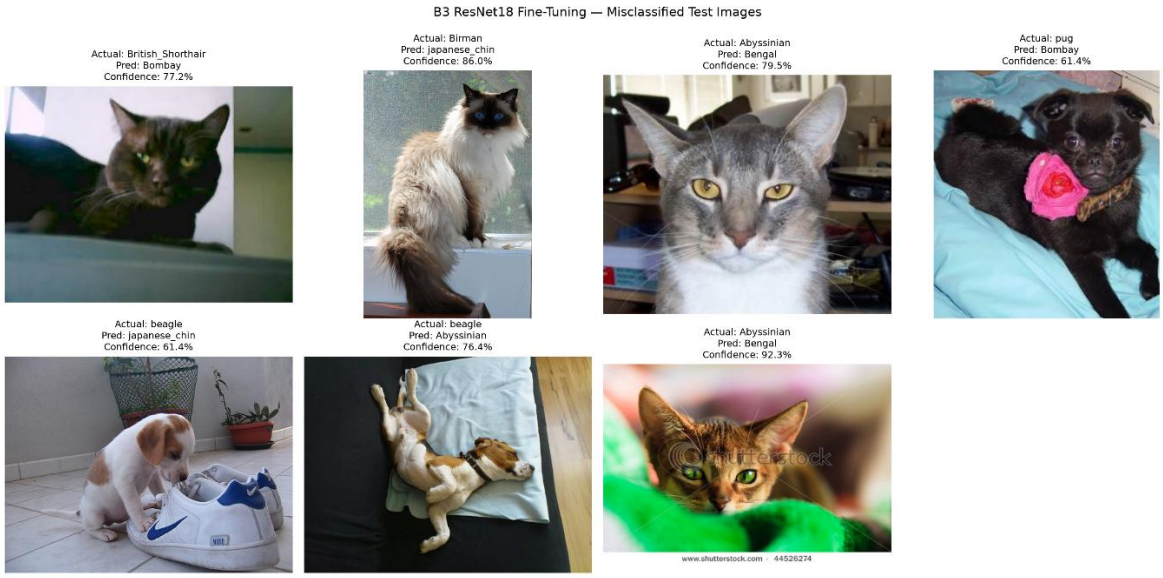
B2 menggunakan feature extraction dengan membekukan backbone dan hanya melatih 5.130 parameter. Strategi ini lebih sederhana dan efisien, dengan test Macro F1 sebesar 0,9731. B3 melakukan fine-tuning pada layer4 dan fully connected layer dengan **learning rate berbeda,** menghasilkan test Macro F1 sebesar 0,9765. B3 memberikan peningkatan performa kecil, tetapi melibatkan lebih banyak trainable parameters. Dengan demikian, B2 cocok ketika efisiensi menjadi prioritas, sedangkan B3 dapat dipilih ketika peningkatan performa lebih diutamakan.

3. Evaluasi Pengaruh Augmentasi Data

Augmentasi berupa random crop, horizontal flip, rotation, dan color jitter dirancang untuk meningkatkan variasi data latih dan mengurangi overfitting. Efektivitasnya dapat dinilai melalui selisih training accuracy dan validation accuracy serta pola loss kedua data tersebut. Namun, hasil eksperimen B4 dengan augmentasi memiliki history dan checkpoint yang identik dengan B2. Oleh karena itu, pengaruh augmentasi belum dapat disimpulkan secara valid dari eksperimen ini. Hasil tersebut menunjukkan perlunya memastikan keterlacakan konfigurasi dan keluaran eksperimen sebelum menarik kesimpulan.

C3. Failure Analysis (Analisis Kasus Misklasifikasi)

Analisis misklasifikasi dilakukan terhadap tujuh citra pada test set yang salah diprediksi oleh model B3. Dari 298 citra uji, model salah mengklasifikasikan tujuh citra.



No.	Ground Truth	Prediksi Model	Confidence	Hipotesis Penyebab
1	British Shorthair	Bombay	77,21%	Kemiripan warna bulu dan bentuk wajah.
2	Birman	Japanese Chin	85,99%	Kemungkinan kemiripan fitur wajah dan bulu pada sudut tertentu.
3	Abyssinian	Bengal	79,52%	Kemiripan pola dan warna bulu.
4	Pug	Bombay	61,41%	Fitur wajah atau bentuk tubuh kurang terlihat jelas pada citra.

5	Beagle	Japanese Chin	61,44%	Kemungkinan sudut pengambilan atau bagian tubuh yang terlihat menimbulkan ambiguitas.
6	Beagle	Abyssinian	76,40%	Kemungkinan fitur visual khas anjing tidak terlihat jelas.
7	Abyssinian	Bengal	92,30%	Kemiripan pola visual membuat model sangat yakin pada kelas yang keliru.

Penyebab pada tabel merupakan hipotesis berdasarkan pasangan kelas yang tertukar, bukan penyebab yang telah dipastikan. Secara umum, hasil ini menunjukkan bahwa confidence score tinggi tidak selalu menjamin prediksi benar. Pemeriksaan lebih lanjut terhadap citra asli diperlukan untuk memastikan apakah kesalahan berkaitan dengan kemiripan visual, sudut pengambilan, pencahayaan, oklusi, atau latar belakang.

C4. Rekomendasi Rekayasa dan Batasan Eksperimen

Berdasarkan hasil eksperimen, transfer learning dengan strategi feature extraction (B2) direkomendasikan sebagai pilihan awal untuk klasifikasi citra dengan data terbatas karena menghasilkan test Macro F1 sebesar 0,9731 dengan hanya 5.130 trainable parameters. Jika peningkatan performa menjadi prioritas, fine-tuning bertahap (B3) dapat dipilih karena menghasilkan test Macro F1 tertinggi, yaitu 0,9765. Sementara itu, MobileNetV2 (B5) dapat dipertimbangkan untuk perangkat dengan keterbatasan komputasi, tetapi waktu inferensi dan penggunaan memorinya perlu diuji sebelum diterapkan.

Eksperimen ini memiliki beberapa keterbatasan, yaitu penggunaan satu random seed, cakupan hanya sepuluh kelas hewan, serta jumlah test set sebanyak 298 citra. Selain itu, hasil B4 dengan augmentasi belum dapat dievaluasi secara independen karena history dan checkpoint-nya identik dengan B2. Durasi pelatihan dan kinerja pada data eksternal juga tidak tercatat atau belum diuji. Oleh karena itu, hasil eksperimen perlu divalidasi lebih lanjut sebelum diterapkan pada kondisi nyata.

Transparansi Penggunaan AI

Saya menggunakan AI jenis ChatGPT dan juga Gemini AI untuk membantu saya brainstorming, mencangkup membantu saya dalam memahami soal, apa saja yang harus saya tulis di laporan ini, dan bagaimana struktur laporan ini sendiri.

Selain itu saya juga menggunakan ChatGPT untuk membantu logic saya dalam melakukan coding dan juga menganalisis hasil training dari masing-masing kategori (B1-B5).